

Analyse de Churn et Rétention Client

Online Retail II Dataset • 2009–2011 • UCI Machine Learning Repository

Objectif : Identifier et segmenter les clients à risque de churn afin d'activer des stratégies de rétention proactives.

Présentateurs :

Malik Hamza Kouotou

Pierre Hubertin Andrianirina

Plan de la présentation

01

Introduction & Contexte

Dataset, entreprise, enjeux business

02

Besoin d'affaires

Définition du churn, justification, valeur ajoutée

03

Données & Nettoyage

1 067 371 lignes → 805 549 lignes propres

04

Analyse Exploratoire (EDA)

Distributions, tendances temporelles, pays

05

Feature Engineering (RFM)

Récence, Fréquence, Valeur, variables enrichies

06

Modélisation & Algorithmes

Logistic Regression, Random Forest, Gradient Boosting

07

Évaluation & Métriques

ROC-AUC, Recall, Precision, F1, matrices

08

Segmentation & Recommandations

4 segments de risque + actions CRM concrètes

Introduction & Contexte

Online Retail II — Dataset e-commerce britannique 2009–2011

1 067 371

Lignes
brutes

5 878

Clients
identifiés

53 628

Factures
distinctes

38

Pays
couverts

2 ans

Historique
2009–2011

Colonnes clés du dataset :

Invoice

N° de facture (préfixe C = annulation)

Customer ID

Identifiant client (22,8 % manquants)

InvoiceDate

Date et heure de la transaction

Quantity

Quantité achetée par ligne de commande

Price

Prix unitaire en livres sterling (£)

Country

Pays de livraison (91,9 % Royaume-Uni)

Besoin d'affaires & Définition du Churn

Pourquoi analyser le churn ? Comment le définir sans abonnement ?

Définition du churn (e-commerce transactionnel)

Un client est « churned » s'il n'a effectué AUCUN achat depuis plus de 90 jours avant la date de référence (10/12/2011).
Justification : seuil empirique basé sur la médiane de récence (96 jours) = cycle d'achat trimestriel typique.

Coût d'acquisition ×5–7

Fidéliser coûte 5 à 7× moins cher qu'acquérir un nouveau client.

Ciblage data-driven

Sans modèle, les campagnes ciblent au hasard → budget marketing gaspillé.

Taux de churn : 50,9 %

2 989 clients sur 5 878 en zone de churn potentiel dans les données.

Résultat attendu : liste priorisée de clients + probabilité de churn + segment de risque → actions CRM immédiates

Données & Pipeline de nettoyage

Étapes 1 & 2 du pipeline — De 1 067 371 lignes brutes à 805 549 lignes propres




Détail des problèmes de qualité :

Customer ID manquant	243 007	22,8 %	Commandes anonymes — non traçables pour la rétention individuelle
Factures annulées (préf. C)	19 494	1,8 %	Retours & annulations — biais si inclus dans le calcul RFM
Quantités négatives	22 950	2,1 %	Erreurs de saisie ou retours non étiquetés en annulation
Prix nuls ou négatifs	6 207	0,6 %	Articles offerts ou erreurs de tarification dans le système source

Importance des variables — Random Forest

La Récence domine largement — signal le plus puissant du désengagement client



 **Interprétation**

#1 Récence
Inactivité récente = signal le plus fort de désengagement imminent.

#2 Fréquence
Clients 1–2 commandes : engagement ténu, vulnérables au churn.

#3 Valeur
Petit CA total → moindre attachement à la marque.

Feature Engineering — Modèle RFM enrichi

8 variables comportementales construites par client à partir des transactions brutes

R

Récence

Jours depuis le dernier achat

Médiane : 96 jours
Max : 739 jours

F

Fréquence

Commandes distinctes par client

Médiane : 3
Max : 398

M

Valeur £

CA total généré par client (£)

Médiane : £899
Max : £608 822

Variables additionnelles :

AvgOrderValue	Valeur moyenne par commande = Monetary / Frequency
CustomerLifespan	Durée de vie (jours entre 1 ^{er} et dernier achat)

PurchaseFreqPerMonth	Fréquence mensuelle = Frequency / mois actifs
NumCountries	Nombre de pays distincts commandés

3 modèles de classification supervisée entraînés et comparés — split 80/20 stratifié

Régression Logistique

BASELINE

✓ Avantages

- Interprétable
- Rapide à entraîner
- Bonne baseline

⚠ Limites

- Suppose la linéarité
- Moins performant

→ Référence de comparaison

Split stratifié 80 % entraînement / 20 % test

- StandardScaler appliqué à la Régression Logistique uniquement

Random Forest

RETENU ★

✓ Avantages

- Robuste aux outliers
- Importance des variables
- Anti-surapprentissage

⚠ Limites

- Moins interprétable
- Plus lent

→ Modèle principal retenu

Gradient Boost

RETENU ✓

✓ Avantages

- Très haute performance
- Capture non-linéarités
- Réduction biais-variance

⚠ Limites

- Plus d'hyperparamètres
- Sensible au bruit

→ Modèle complémentaire

Métriques d'évaluation

Pourquoi l'Accuracy seule ne suffit pas — les deux erreurs n'ont pas le même coût

❌ Faux Négatif (FN) — COÛT ÉLEVÉ

Prédit ACTIF alors que le client PART → client perdu, CA définitivement perdu.

⚠️ Faux Positif (FP) — COÛT MODÉRÉ

Prédit CHURNER alors qu'il reste actif → offre de rétention gaspillée, coût marginal.

Métrique	Formule	Priorité	Rôle en rétention
ROC-AUC	Aire sous courbe ROC	★★★★	Comparaison globale des modèles sur tous les seuils
Recall (churn) ★	$VP / (VP + FN)$	★★★★★	PRIORITAIRE : maximiser la détection des churners
Precision (churn)	$VP / (VP + FP)$	★★★	Éviter de relancer des clients fidèles (coût CRM)
F1-score	$2 \times P \times R / (P + R)$	★★★	Équilibre P/Recall si budget de rétention limité
Avg Precision	Aire sous courbe P-R	★★	Plus robuste que ROC-AUC en cas de déséquilibre de classes

Résultats — Comparaison des modèles

Random Forest et Gradient Boost surpassent la Régression Logistique sur tous les indicateurs

Modèle	ROC-AUC	Recall	Precision	F1
Régression Logistique	~0,84	~0,82	~0,83	~0,82
Random Forest ★	~0,95	~0,91	~0,92	~0,91
Gradient Boosting	~0,94	~0,90	~0,91	~0,90

ROC-AUC comparatif :



🏆 Random Forest — Modèle retenu

- ROC-AUC = 0,95 (quasi-parfait)
- Recall = 0,91 (91 % des churners détectés)
- Importance des variables → interprétabilité business

Segmentation des clients à risque

4 niveaux de risque basés sur la probabilité de churn prédite par le Random Forest

 Critique	 À risque	 Attention	 Fidèle
Probabilité : ≥ 75 %	Probabilité : 50–75 %	Probabilité : 25–50 %	Probabilité : < 25 %
Clients : ~750 (12,8 %)	Clients : ~1 200 (20,4 %)	Clients : ~1 000 (17,0 %)	Clients : ~2 900 (49,3 %)
Action CRM : Appel personnel + offre réactivation -20 %, semaine 1	Action CRM : Email ciblé « Vous nous manquez » + reco produits	Action CRM : Newsletter enrichie + programme de fidélité renforcé	Action CRM : Programme de récompenses & cross-sell premium

Difficultés rencontrées & Compétences acquises

Difficultés rencontrées

Données manquantes

22,8 % des lignes sans Customer ID → transactions non traçables pour la rétention.

Définition du churn

Pas de résiliation formelle → seuil de 90 jours défini empiriquement sur la médiane de récence.

Distributions asymétriques

CA max = £608 822 vs médiane £899 → outliers extrêmes sans transformation log.

Interprétabilité vs performance

Gradient Boosting légèrement meilleur mais RF retenu pour l'explicabilité métier.

Compétences acquises

Techniques

- Pipeline data science complet
- Feature engineering RFM
- Scikit-learn : LR, RF, GB
- Métriques multi-critères
- Visualisations avancées

Business

- Traduction problème → ML
- Définition métrique churn
- Segmentation CRM actionnable
- Communication résultats mixtes

Conclusion & Recommendations business

0,95

ROC-AUC
Random Forest

91 %

Recall churn
Churners détectés

~1 950

Clients ciblés
Critique + À risque

50,9 %

Taux de churn
Dataset nettoyé



Recommandations & Perspectives

Court terme (0–30 j)

Lancer la campagne ciblée pour les ~750 clients critiques (prob. $\geq 75\%$).
Offre de réactivation personnalisée — intervention immédiate.

Moyen terme (1–3 mois)

Déploiement batch mensuel : actualiser les scores de churn et alimenter le CRM automatiquement pour toute la base.

Long terme

Enrichir le modèle avec catégories produit, saisonnalité et module CLV (Customer Lifetime Value) pour prioriser par valeur.

Merci pour votre attention !

Questions & Réponses

Rappel des résultats clés :

- ✓ Taux de churn de 50,9 % identifié sur 5 878 clients (seuil : 90 jours d'inactivité)
- ✓ Random Forest — ROC-AUC $\approx 0,95$ | Recall ≈ 91 % sur la classe churn
- ✓ Récence = variable prédictive dominante (≈ 42 % d'importance Gini)
- ✓ 4 segments actionnables générés pour l'équipe CRM avec actions prioritées
- ✓ Code Python complet & reproductible (544 lignes, 10 sections commentées)

Malik Hamza Kouotou • Pierre Hubertin Andrianirina